2º Trabalho de Fundamentos de Inteligência Artificial

Ana, S. B. Silva, Davi, T. de Moraes, Gabriel, J. L. dos Santos
Sebastian, L. Guedes, Vinicius, O. de Souza

[1]Instituto de Computação (IComp)
Universidade Federal do Amazonas (UFAM)
Manaus – AM
Professor: Edjard Mota

{ana.silva, davi.moraes, gabriel.santos}@icomp.ufam.edu.br

{sebastian.guedes, vinicius.souza}@icomp.ufam.edu.br

1. Metodologia

O trabalho investiga a variação do desempenho em Matemática no Ensino Médio no contexto do Novo Ensino Médio, utilizando árvores de decisão, modelos lineares, modelos probabilísticos e lógica fuzzy. Para fins experimentais, considera-se 2021 como o período anterior à implementação e 2023 como o posterior. Essa associação é uma premissa metodológica, não uma confirmação das datas efetivas de implementação em cada município; os resultados indicam, portanto, associações, e não efeitos causais.

Usamos a média de Matemática da última série do Ensino Médio (`MEDIA_12_MT`) do SAEB 2021 e 2023 por município (INEP, dados abertos) e o IDHM-Renda de 2010 (Censo/Atlas do Desenvolvimento Humano; data de acesso: [preencher]). As abas do SAEB trazem linhas agregadas e sobrepostas ("Total", "Estadual e Municipal"), que duplicariam municípios e causariam vazamento na validação cruzada. Por isso, a unidade de análise é *município* × *dependência* × *localização*, só com categorias exclusivas (Estadual, Federal ou Municipal; Urbana ou Rural): 3.519 exemplos de 3.102 municípios, 63,1% com melhora. O SAEB 2025 não foi usado. Em todas as etapas, a validação é um 5-fold agrupado por município (semente 42), com as mesmas partições.

Utilizamos modelos de linguagem (LLMs), como GPT, Claude e Gemini, como apoio à formatação do relatório em LaTeX e à implementação dos códigos dos notebooks. Os códigos foram executados, e os resultados das implementações próprias foram conferidos contra bibliotecas de referência (scikit-learn e pgmpy).

2. Etapa 1 – Aprendizado Simbólico

2.1. Alvo, atributos e ganho de informação

A variável-alvo `ALVO_MELHORA` vale 1 quando a média de Matemática de 2023 supera a de 2021 e 0 nos demais casos. Os cinco atributos categóricos são `CO_UF` (27 valores), `DEPENDENCIA_ADM`, `LOCALIZACAO`, `FAIXA_MEDIA_2021` (média de 2021 com cortes fixos em 250, 265 e 280 pontos) e `FAIXA_IDHM_R` (cinco faixas oficiais do IDHM).

Para um conjunto S e um atributo A, com p_i a proporção da classe i e S_v o subconjunto com $A = v$:

$$H(S) = -\sum_i p_i \log_2 p_i, \qquad IG(S, A) = H(S) - \sum_v \frac{|S_v|}{|S|} H(S_v).$$

Na raiz, $p_1 = 0{,}631$ e $H(S) = 0{,}950$ bit. Para `FAIXA_MEDIA_2021`, os quatro ramos dão $0{,}220 \cdot 0{,}398 + 0{,}263 \cdot 0{,}755 + 0{,}304 \cdot 1{,}000 + 0{,}213 \cdot 0{,}899 = 0{,}781$, logo $IG = 0{,}950 - 0{,}781 = 0{,}169$, o maior entre os atributos. A Tabela 1 traz a raiz e o nível 1.

Tabela 1. Entropia e ganho de informação (IG) na raiz e no nível 1. Em negrito, o atributo escolhido.

Nó	n	$P(1)$	H	FAIXA_MEDIA	CO_UF	FAIXA_IDHM	LOCALIZ.	DEPEND.
Raiz	3519	0,63	0,950	**0,169**	0,100	0,061	0,001	0,000
<250	775	0,92	0,398	—	**0,053**	0,004	0,005	0,000
250–265	925	0,78	0,755	—	**0,076**	0,016	0,001	0,000
265–280	1069	0,51	1,000	—	**0,100**	0,015	0,000	0,000
≥280	750	0,31	0,898	—	**0,077**	0,004	0,002	0,000

No nível 2, `CO_UF` abre 27 ramos pequenos. Por exemplo, no nó (265–280, SP; $n = 241$) `FAIXA_IDHM_R` lidera (ganho 0,007), e no nó (<250, MA; $n = 174$) `LOCALIZACAO` lidera (0,020). Os ganhos caem rápido, e o ganho de informação favorece atributos com muitos valores, como `CO_UF`.

2.2. Implementação, comparação e resultados

Implementamos `LEARN-DECISION-TREE` (ID3) do zero, conforme o pseudocódigo do enunciado, com `max_depth` como pré-poda, e comparamos com `DecisionTreeClassifier(criterion='entropy')` sobre atributos *one-hot*. Como o scikit-learn só faz divisões binárias, as estruturas diferem (o ID3 abre um filho por valor), o que explica a diferença de profundidade na Tabela 2; ambos escolhem `FAIXA_MEDIA_2021` na raiz.

Tabela 2. Métricas de avaliação dos classificadores.

Métrica	Implementação própria	Scikit-learn
Acurácia de treinamento (sem poda)	0,776	0,776
Acurácia média 5-fold (sem poda)	0,738	0,737
Acurácia média 5-fold (podada)	0,739	0,738
Profundidade (sem poda / podada)	5 / 2	30 / 4
Baseline (classe majoritária), 5-fold	0,631	

As duas implementações têm desempenho equivalente: cerca de 74% na validação, 11 pontos acima do baseline e dentro da faixa esperada no enunciado (72–80%). A regra dominante é `FAIXA_MEDIA_2021`: a taxa de melhora cai de 92% (média inicial <250) para 32% (≥280), em grande parte por *regressão à média*. Somam-se o SAEB 2021 em pandemia e o IDHM de 2010, defasado; a árvore, portanto, não demonstra efeito do Novo Ensino Médio.

2.3. Monotonicidade

Na lógica clássica, o raciocínio é monotônico: se uma base de conhecimento permite concluir α, acrescentar novas premissas nunca invalida α. O aprendizado de árvores de decisão não tem essa propriedade. A árvore é uma generalização feita a partir dos

exemplos disponíveis, e a estrutura depende da distribuição das classes e dos ganhos de informação calculados em cada nó. Por isso, um exemplo novo pode alterar o atributo da raiz, os ramos abaixo dele e as regras de classificação. Uma regra aprendida com um conjunto inicial é uma conclusão provisória, que vale enquanto os dados a sustentarem, e não uma conclusão permanente. O mesmo ocorre ao atualizar probabilidades com novas evidências, como nas Etapas 3 a 5.

Verificamos isso com subconjuntos aninhados dos dados, cada um contendo o anterior. Com 40 exemplos, o maior ganho na raiz é de `CO_UF` (0,386), contra 0,167 de `FAIXA_MEDIA_2021`; com 200, os dois quase empatam (0,231 e 0,230); com 500 exemplos, `FAIXA_MEDIA_2021` passa a liderar (0,182), e com todos os 3.519 o ganho dela é 0,169, contra 0,100 de `CO_UF`. Ou seja, uma regra baseada no estado, que parece sensata para a amostra pequena, é descartada quando chegam novos municípios. Entre as árvores de 40 e de 200 exemplos, 24% dos municípios mudam de classe; por exemplo, vários municípios de Rondônia, que a árvore menor classificava como "melhora", passam a ser classificados como "não melhora". A instabilidade também aparece ao reamostrar: em 300 amostras aleatórias de 60 exemplos, a raiz foi `CO_UF` em 250 e `FAIXA_MEDIA_2021` em apenas 50.

No contexto deste trabalho, isso significa que os padrões encontrados entre características municipais e a melhora em Matemática dependem dos municípios usados no treino. Novos dados, como a edição de 2025 do SAEB, podem trocar a raiz e as regras, e uma regra como "média inicial baixa implica melhora" pode deixar de valer ou mudar de força. Assim, a árvore deve ser reconstruída e reavaliada a cada novo conjunto de dados, a estabilidade do modelo deve ser verificada (como fizemos acima) antes de usá-lo para decidir, e as regras aprendidas não devem ser tratadas como conhecimento estável. Essa é uma das razões para preferir, nas etapas seguintes, modelos que expressam a incerteza em probabilidades, e não em regras absolutas.

3. Etapa 2 – Aprendizado Linear

Para os modelos lineares, o alvo contínuo é a variação da nota, $\Delta = \texttt{MEDIA_12_MT_2023} - \texttt{MEDIA_12_MT_2021}$ (média de 3,8 e desvio-padrão de 12,9 pontos); `ALVO_MELHORA` é apenas o sinal de Δ. Como a regressão exige números, os atributos são a nota de 2021, o IDHM-Renda, `Rural` (0/1), `Estadual` (0/1) e a região (Norte, Nordeste, Sudeste, Sul e Centro-Oeste, em vez das 27 UFs, para manter poucos coeficientes legíveis). Todos foram padronizados.

Implementamos do zero a regressão univariada, pela fórmula fechada, usando só a nota de 2021, e a multivariada, por gradiente descendente, seguindo o pseudocódigo do enunciado. Também implementamos a regularização L2 (Ridge) e a regressão logística para `ALVO_MELHORA`, e comparamos tudo com `LinearRegression`, `Ridge` e `LogisticRegression` do scikit-learn (Tabela 3). Cada ponto a mais em 2021 reduz em cerca de 0,33 ponto a variação esperada, e a nota de 2021 é o atributo dominante; IDHM-Renda, localização, dependência e região têm efeito pequeno. Na regularização, os coeficientes encolhem à medida que λ cresce (curva no notebook), mas o melhor λ (≈ 14) dá o mesmo R^2 do modelo sem regularização: com 8 atributos e 3,5 mil exemplos, não há excesso de ajuste a corrigir.

As implementações próprias reproduzem o scikit-learn em todas as métricas. Os

Tabela 3. Métricas da Etapa 2 (5-fold agrupado por município).

Métrica	Implementação própria	Scikit-learn
R^2 univariada (fórmula fechada)	0,254	0,254
RMSE univariada	11,10	11,10
R^2 multivariada (gradiente)	0,287	0,287
RMSE multivariada	10,86	10,86
R^2 Ridge ($\lambda \approx 14$)	0,287	0,287
RMSE Ridge	10,86	10,86
Acurácia da logística	0,741	0,741
Baseline (classe majoritária)	0,631	

modelos explicam cerca de 29% da variação da nota (erro médio de 10,9 pontos), e a logística acerta 74,1%, o mesmo patamar da árvore da Etapa 1 e 11 pontos acima do baseline. Esses valores ficam abaixo do esperado no enunciado (R^2 de 0,55 a 0,82; logística de 78 a 85%), pois o alvo é a diferença entre duas medições ruidosas de médias municipais, difícil de prever com poucos atributos. O sinal negativo da nota de 2021 reflete, em boa parte, regressão à média, e não efeito do Novo Ensino Médio; o modelo linear tampouco capta as interações com a UF que a árvore encontrou.

4. Etapa 3 – Probabilidade

Usamos três variáveis binárias: M (a média de Matemática melhorou entre 2021 e 2023), B (média inicial baixa, abaixo de 265 pontos em 2021) e I (IDHM-Renda baixo, abaixo de 0,6). As probabilidades são frequências relativas nos 3.519 exemplos. A Tabela 4 mostra a distribuição conjunta de M e B (quatro eventos atômicos, soma 1). Dela saem as marginais, $P(M{=}1) = 0{,}631$ e $P(B{=}1) = 0{,}483$, e as condicionais: quem partiu de média baixa melhorou em 84,6% dos casos, contra 43,0% de quem partiu de média alta. As variáveis são, portanto, dependentes, o que repete a regressão à média das etapas anteriores.

Tabela 4. Distribuição conjunta de M (melhorou) e B (média inicial baixa).

	$B=0$	$B=1$
$M=0$	0,294	0,075
$M=1$	0,223	0,409

Com três variáveis, a regra da cadeia, $P(B, I, M) = P(B)\,P(I \mid B)\,P(M \mid B, I)$, reproduz exatamente os oito eventos atômicos, sem supor independência. O Teorema de Bayes permite inverter o raciocínio: o sentido *causal*, $P(M \mid B) = 0{,}846$, descreve o que acontece a quem parte de média baixa; o sentido *diagnóstico*, que parte do resultado observado, dá $P(B \mid M) = \frac{0{,}846 \cdot 0{,}483}{0{,}631} = 0{,}647$. Saber que o município melhorou eleva de 48% para 65% a chance de ele ter partido de média baixa. Isso é inferência sobre dados observados, e não efeito do Novo Ensino Médio.

Verificamos também se B e I são independentes dado M, suposição do Naive Bayes da etapa seguinte. Não são: entre os municípios que melhoraram, o par ($B{=}1$,

I=1) ocorre em 34% dos casos, contra 26% se fossem independentes. Renda baixa e média inicial baixa andam juntas mesmo sabendo se houve melhora, e essa suposição será violada na Etapa 4. Por fim, a lógica de primeira ordem não expressa "85% de chance": a regra $\forall x\,(B(x) \rightarrow M(x))$ é falsa, pois tem 262 contraexemplos (15,4% dos 1.700 municípios com $B = 1$), e a lógica descarta a regra em vez de medir o quanto ela vale. A probabilidade representa esse grau de crença, permite condicionar em evidências e ser aprendida dos dados.

5. Etapa 4 – Aprendizado Probabilístico e EM

Estimamos a probabilidade de melhora, $\theta = P(M{=}1)$, de duas formas. O MLE é a frequência observada, $\hat{\theta} = 2221/3519 = 0{,}631$. O MAP com prior Beta(2,2) equivale a somar uma observação de cada resultado, $\hat{\theta} = (k+1)/(n+2)$, e também dá 0,631 com tantos dados; a diferença aparece com poucos exemplos: em 3 sucessos de 3, o MLE afirma $\theta = 1$ e o MAP, 0,8. É a mesma ideia da suavização de Laplace ($\alpha = 1$) usada no Naive Bayes que implementamos do zero para `ALVO_MELHORA`, com os mesmos cinco atributos da Etapa 1 e resultado idêntico ao `CategoricalNB` do scikit-learn. Ele acerta 71,2% (baseline 63,1%), abaixo da árvore e da logística ($\approx$74%), o que é coerente com a suposição de independência condicional que a Etapa 3 mostrou ser violada.

Para relaxar essa suposição, acrescentamos uma variável oculta Z com K valores dentro de cada classe: os atributos passam a ser independentes dado (C, Z), mas não mais dado só C. Como Z não é observada, usamos o EM: o passo E calcula a probabilidade de cada município pertencer a cada subgrupo, e o passo M reestima as tabelas com essas contagens esperadas. Rodamos também o pseudocódigo do enunciado (EM gaussiano) sobre o `IDHM_R`, sem usar o alvo nem a região: surgiram dois grupos, um de 36% dos municípios com IDHM médio 0,56 (86% do Norte/Nordeste) e outro de 64% com 0,70, com a mesma log-verossimilhança (4105,67) em 10 inicializações e igual à do `GaussianMixture`. A log-verossimilhança do Naive Bayes com Z sobe de forma monotônica e estabiliza em cerca de 26 iterações com $K = 2$ e 50 com $K = 3$ (curvas no notebook).

Tabela 5. Etapa 4: Naive Bayes puro e com EM (5-fold agrupado por município).

Modelo	Treino	Teste (5-fold)	Desvio	Parâmetros
Baseline majoritário	—	0,631	—	1
Naive Bayes puro ($K = 1$)	0,719	0,712	0,019	73
Naive Bayes + EM ($K = 2$)	0,738	0,726	0,017	147
Naive Bayes + EM ($K = 3$)	0,740	0,734	0,013	221

O EM melhora o Naive Bayes em 1,4 ponto ($K = 2$) e 2,3 pontos ($K = 3$), e em todas as 5 partições, a custa de mais parâmetros. Porém, o ganho é menor que o desvio entre partições (1,3 a 1,9 ponto): é indício, não prova. Os valores ficam abaixo do esperado no enunciado (Naive Bayes 72–78%; com EM, 80–86%). Duas ressalvas: o EM só garante máximo local (por isso usamos várias inicializações) e o $K = 3$ foi escolhido olhando o teste, o que é um pouco otimista.

6. Etapa 5 – Redes Bayesianas

A rede tem cinco nós binários: R (região Norte/Nordeste), I (IDHM-Renda baixo), U (escola rural), B (média inicial baixa) e M (melhorou); a dependência administrativa ficou de fora porque 99,4% das linhas são estaduais. As sete arestas seguem a ordem do tempo (Censo 2010, SAEB 2021, SAEB 2023) e o domínio: $R \to I$ (renda é menor no Norte/Nordeste); $R \to U$ (a proporção de escolas rurais varia entre regiões); $R \to B$, $I \to B$ e $U \to B$ (região, renda e ruralidade condicionam o desempenho inicial); $B \to M$ (regressão à média) e $I \to M$ (a renda pode influenciar a melhora além do ponto de partida). Comparamos a estrutura pelo critério BIC: retirar qualquer aresta piora o ajuste, exceto $U \to B$, que é um empate técnico e foi mantida por razão de domínio. As tabelas de probabilidade condicional (CPTs) foram estimadas dos dados com suavização de Laplace; por exemplo, $P(I{=}1 \mid R{=}1) = 0{,}77$ contra 0,055 nas demais regiões, e a chance de melhora vai de 0,80–0,89 com média inicial baixa a 0,42–0,50 com média inicial alta.

Implementamos do zero a inferência por enumeração e comparamos com a eliminação de variáveis do pgmpy: o resultado é idêntico (diferença menor que 10^{-15} em 405 consultas), e as CPTs estimadas também coincidem. Por exemplo, saber só que o município é do Norte/Nordeste e rural eleva $P(M{=}1)$ de 0,63 para 0,80. Na d-separação, nosso teste concorda com o do pgmpy em 80 de 80 casos. Duas independências lidas do grafo se confirmaram nos dados: dados B e I, nem a região nem a ruralidade informam sobre M (informação mútua de cerca de 0,001 bit; p = 0,14 e 0,33). Já condicionar só em B deixa R informativa, pois o caminho $R \to I \to M$ segue aberto. B é um colisor em $I \to B \leftarrow U$: com R fixo, I e U são independentes, mas ao observar B o caminho se abre e saber que a escola é rural passa a mudar a crença sobre a renda (até 5 pontos percentuais; efeito modesto, pois U pesa pouco sobre B).

A rede tem $1+2+2+8+4 = 17$ parâmetros livres contra $2^5 - 1 = 31$ da conjunta (45% a menos); a economia é menor que a do exemplo do enunciado ($\sim$10) porque B tem três pais. Como classificador de `ALVO_MELHORA`, ela acerta 69,7% (Tabela 6), abaixo do Naive Bayes e da árvore: usa variáveis binarizadas, e a independência $M \perp R, U \mid \{B, I\}$ faz só B e I entrarem na decisão. Em troca, usa só 17 parâmetros (contra 73 e 221) e é totalmente interpretável; seu valor está na inferência e na explicação, não na acurácia.

Tabela 6. Etapa 5: Rede Bayesiana como classificador (5-fold agrupado por município).

Modelo	Teste (5-fold)	Parâmetros
Baseline majoritário	0,631	1
Naive Bayes puro (Etapa 4)	0,712	73
Naive Bayes + EM, $K = 3$ (Etapa 4)	0,734	221
Rede Bayesiana (Etapa 5)	0,697	17

7. Etapa 6 – Lógica Fuzzy e pipeline integrado

O sistema Mamdani combina a saída da Etapa 5 com o nível de desempenho. Há duas entradas e uma saída, todas com funções de pertinência triangulares: *risco* de não melhorar, $1 - P(M{=}1 \mid R, I, U, B)$, calculado pela rede por enumeração e fora da amostra

(baixo e alto, que se cruzam em 0,5); *nota* SAEB 2021 (baixa e alta, entre 230 e 300, que se cruzam em 265, o corte da Etapa 3); e *prioridade* de apoio, de 0 a 100 (baixa, média e alta). As regras são três: R1, **se** a nota é baixa **então** a prioridade é alta; R2, **se** a nota é alta **e** o risco é alto **então** a prioridade é média (queda provável a partir de um patamar alto: monitorar); R3, **se** a nota é alta **e** o risco é baixo **então** a prioridade é baixa. Usamos o `scikit-fuzzy` (E = mínimo, agregação por máximo e centroide), conferido por uma versão em `numpy` (diferença de até 0,02 em 0–100).

Na fronteira, o grupo $B{=}0$, $I{=}1$ tem risco de 0,502: o limiar rígido de 0,5 manda intervir por uma diferença de 0,002, enquanto no fuzzy a prioridade varia só 0,4 ponto entre risco 0,49 e 0,51. Em 200 reamostragens (*bootstrap*) das CPTs, 3,7% dos municípios trocam de decisão no limiar rígido (até 8,2%), contra variação média de 0,16 ponto no fuzzy, sem nenhum município com mudança maior que 5 pontos (em parte porque o risco pesa pouco na saída). Contra os desfechos de 2023 (Tabela 7), as duas decisões respondem a perguntas diferentes. Para achar quem terminou com média baixa, o limiar sobre a probabilidade da rede é pior que sortear (precisão de 14% contra 41,5% de prevalência), porque marca quem partia de nota alta e tem "risco" de cair; o fuzzy, que põe o nível na frente, chega a 70%. Para prever "não melhorou", o resultado se inverte: o limiar da rede, treinada para isso, acerta 57% dos marcados (prevalência de 36,9%) e o fuzzy, 16%.

Tabela 7. Etapa 6: decisão rígida (limiar 0,5) e fuzzy frente aos desfechos de 2023. Todas marcam os mesmos 1.709 municípios (48,6%).

Desfecho (prevalência)	Decisão	Precisão	Recall	AUC
Média 2023 $<$ 265 (41,5%)	Rígida: risco $>$ 0,5 (rede)	0,138	0,161	0,178
	Fuzzy	0,700	0,820	0,880
	Só a nota 2021 (referência)	0,709	0,829	0,881
Não melhorou (36,9%)	Rígida: risco $>$ 0,5 (rede)	0,568	0,747	0,731
	Fuzzy	0,155	0,204	0,218
	Só a nota 2021 (referência)	0,154	0,203	0,215

O fuzzy supera o limiar rígido nas fronteiras ambíguas, com dados ruidosos e quando é preciso combinar fontes de forma legível; não o supera quando a pergunta é exatamente a que a probabilidade foi treinada para responder. Ele também empata com a nota sozinha (AUC 0,880 contra 0,881), pois risco e nota têm correlação de cerca de 0,8: seu ganho é suavidade e interpretabilidade, não acurácia. Cada decisão é explicável pelas regras: um município com nota 240 e risco 0,11 ativa R1 com grau 0,86 e recebe prioridade 69,9, e um gestor pode contestar o corte de 265 e ajustar a regra. Os parâmetros dos triângulos foram escolhidos à mão, e a primeira versão das regras (simétrica entre nota baixa e alta) foi revisada ao conferir com os desfechos, então os números da Tabela 7 têm algum otimismo.

Pipeline integrado

A Figura 1 mostra o encadeamento: os dados oficiais alimentam a árvore (Etapa 1), cujas faixas e cortes reaparecem na rede e no fuzzy; as etapas 2 a 4 exploram os mesmos dados com modelos lineares e probabilísticos; a Etapa 3 fornece as variáveis binárias e o raciocínio de Bayes da rede; e a probabilidade da Etapa 5 entra como *risco* no sistema fuzzy, que produz a decisão final interpretável.

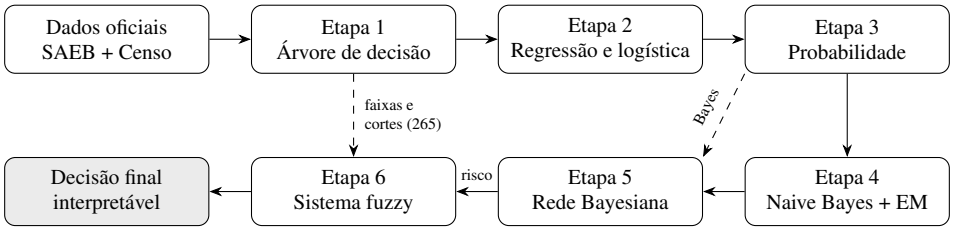


Figura 1. Pipeline integrado. Setas tracejadas: reaproveitamento de resultados de etapas anteriores.

8. Conclusão

Quatro resultados atravessam o trabalho. Primeiro, a regressão à média domina tudo: a nota de 2021 é o principal preditor em todas as etapas, e nenhum modelo demonstra efeito do Novo Ensino Médio. Segundo, a acurácia fica em 73–74% na árvore, na logística e no Naive Bayes com EM (contra 63,1% do baseline), e modelos mais complexos não trouxeram ganho confiável. Terceiro, a rede bayesiana (69,7%) e o sistema fuzzy trocam um pouco de acurácia por interpretabilidade: a rede explicita as dependências, e o fuzzy transforma a probabilidade em uma recomendação legível e estável perto dos limiares. Quarto, todos os valores ficaram abaixo dos "gabaritos" do enunciado, pois o alvo compara duas medições ruidosas de médias municipais com poucos atributos; reportamos o que foi obtido.

9. Referências

INEP. *Saeb: resultados*. Instituto Nacional de Estudos e Pesquisas Educacionais Anísio Teixeira. Disponível em: `https://www.gov.br/inep/pt-br/areas-de-atuacao/avaliacao-e-exames-educacionais/saeb/resultados`. Acesso em: 26 out. 2026.

PNUD Brasil, Ipea e Fundação João Pinheiro. *Atlas do Desenvolvimento Humano no Brasil: consulta (planilha)*. Disponível em: `https://www.atlasbrasil.org.br/consulta/planilha`. Acesso em: 29 out. 2026.

Russell, S. e Norvig, P. (2020). *Artificial Intelligence: A Modern Approach*. 4ª ed., Pearson (caps. 18–20).

Zadeh, L. A. (1965). Fuzzy sets. *Information and Control*, 8(3), 338–353.

Hüllermeier, E. (2011). Fuzzy machine learning and data mining. *WIREs Data Mining and Knowledge Discovery*, 1(4), 269–283.

Bibliotecas: scikit-learn, scikit-fuzzy, pgmpy, numpy, pandas.